Anticipando la Producción de Vino para Optimizar la Vendimia

Stratton Oakmont Consulting

Marzo 2026

Modelo predictivo para optimizar la planificación y toma de decisiones de *Se nos fue de las Manos*

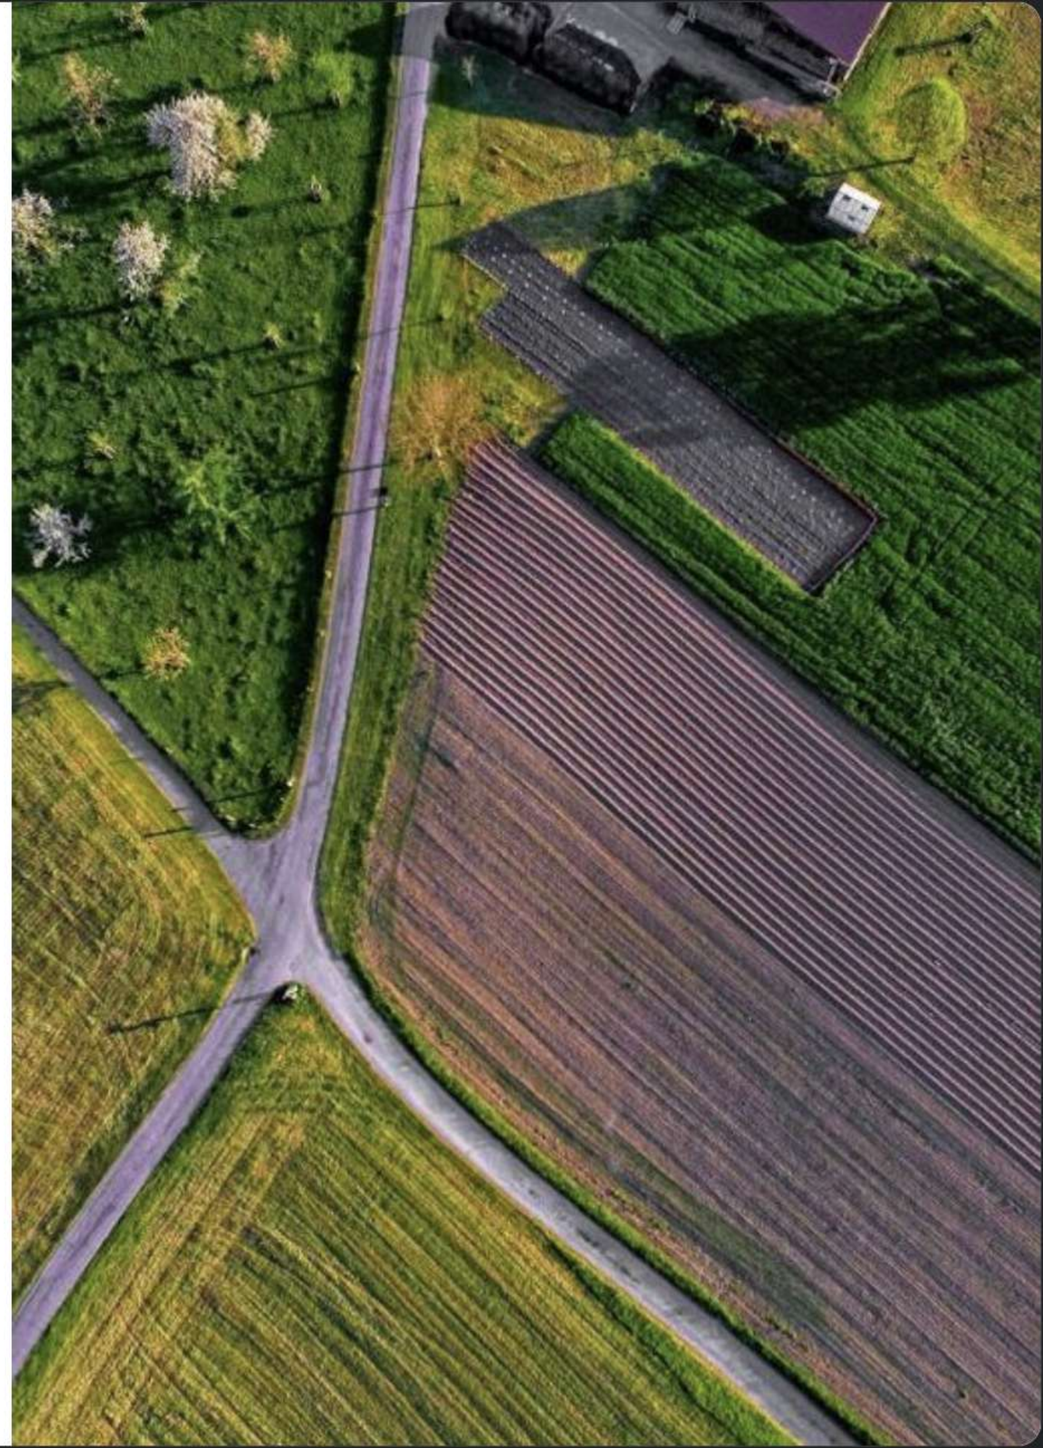

Incertidumbre en la Planificación Agrícola

La variabilidad climática y la falta de modelos predictivos precisos dificultan estimar la producción final antes de la campaña, impactando directamente en la rentabilidad y eficiencia operativa.

Impacto crítico en márgenes y logística

PUNTOS DE DOLOR

- **Alta incertidumbre en la estimación:** Dificultad para predecir el volumen de cosecha antes del inicio de la campaña.
- **Planificación logística ineficiente:** Riesgo de contratar transporte y almacenamiento insuficiente o excesivo.
- **Gestión de compras reactiva:** Adquisición de consumibles basada en históricos estáticos en lugar de predicciones dinámicas.
- **Compromisos comerciales arriesgados:** Posibilidad de incumplir contratos de venta o perder oportunidades por subestimación.
- **Volatilidad en márgenes:** El sobre-stock o quiebre de stock afecta directamente el resultado financiero final.

Objetivo del Proyecto

Desarrollar una capacidad analítica avanzada para anticipar la producción agrícola y optimizar la toma de decisiones.

01 Desarrollar un modelo predictivo robusto

Capaz de estimar la producción agrícola futura utilizando datos históricos de parcelas, cultivos y clima con alta precisión.

02 Reducir el error de previsión

Minimizar la incertidumbre actual en las estimaciones manuales para mejorar la planificación logística y comercial.

03 Herramienta para la toma de decisiones

Entregar una solución interpretable que permita a los stakeholders de negocio entender qué factores impactan más en el rendimiento.

04 Validación con datos reales

Evaluar múltiples algoritmos de Machine Learning para identificar la mejor tecnología aplicable a nuestro contexto específico.

Datos Utilizados

Resumen del dataset tras el proceso de limpieza y transformación

Volumen Total

8,526 registros

Dataset final limpio y procesado

Dimensionalidad

180 variables

Tras aplicar One-Hot Encoding a categóricas

La base de datos integra información de múltiples fuentes: características de parcelas, datos de cultivo, ubicación geográfica y registros históricos de producción.

Estrategia de Validación

5,985

70% Train

Conjunto de Entrenamiento

Utilizado para que los algoritmos aprendan los patrones entre las variables y la producción.

1,497

30% Validation

Conjunto de Validación

Datos no vistos durante el entrenamiento para evaluar la capacidad de generalización real.

Nota: Esta división garantiza que las métricas de error reportadas reflejen el comportamiento esperado en producción real.

Principales Insights del EDA

El Análisis Exploratorio de Datos reveló patrones fundamentales que guiaron la estrategia de modelado, confirmando la calidad del histórico disponible.

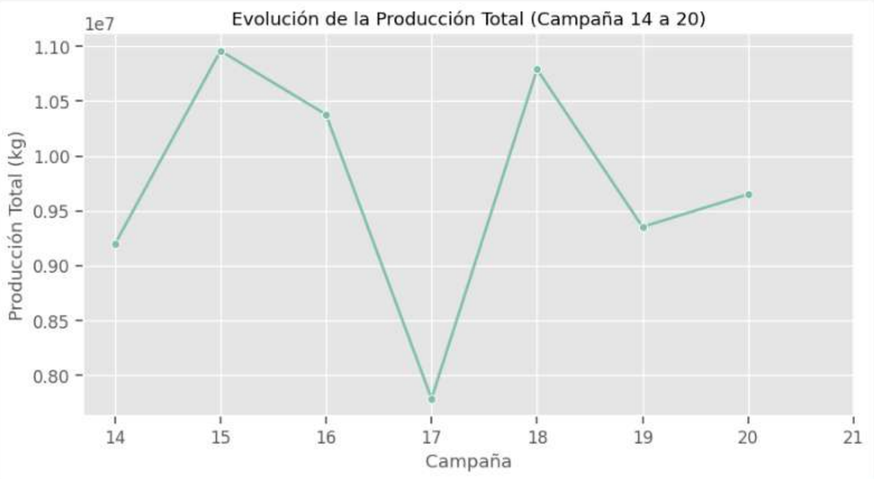

01. Relación directa con el histórico

La producción histórica y la superficie cultivada mostraron una correlación positiva fuerte con la producción actual, validándolas como las variables predictoras más potentes del dataset.

02. Variabilidad geográfica significativa

Se detectaron diferencias estructurales claras en el rendimiento según la zona y ubicación de la parcela. La altitud también juega un rol diferenciador, actuando como proxy de condiciones microclimáticas.

03. Impacto de las condiciones climáticas

Las variables climáticas aportan señal relevante para ajustar las predicciones estacionales. Además, se identificaron y trataron valores atípicos (outliers) que podían distorsionar el entrenamiento del modelo.

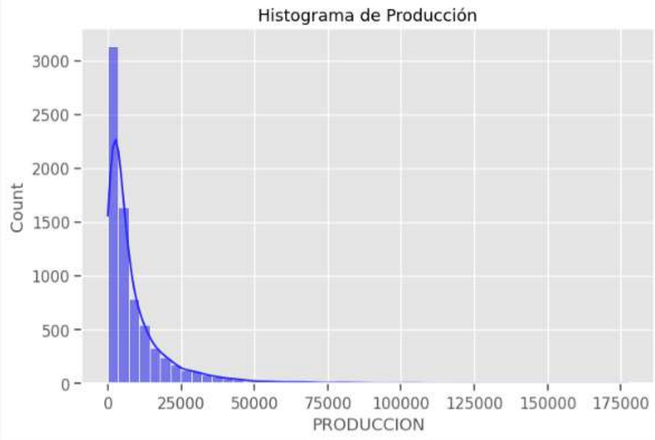

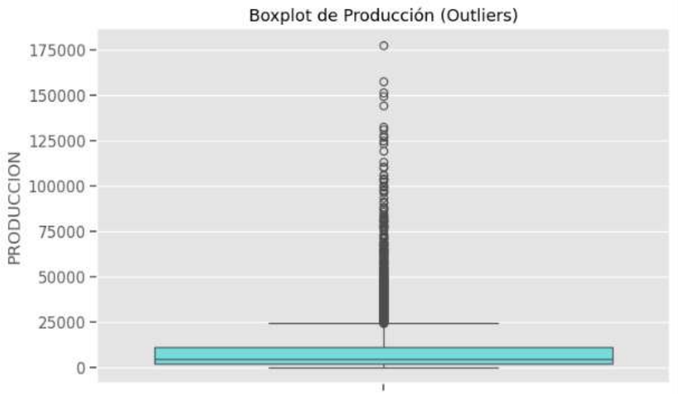

Preparación de Datos

Transformación rigurosa de datos brutos en un dataset limpio y estructurado, optimizado para el entrenamiento de modelos predictivos.

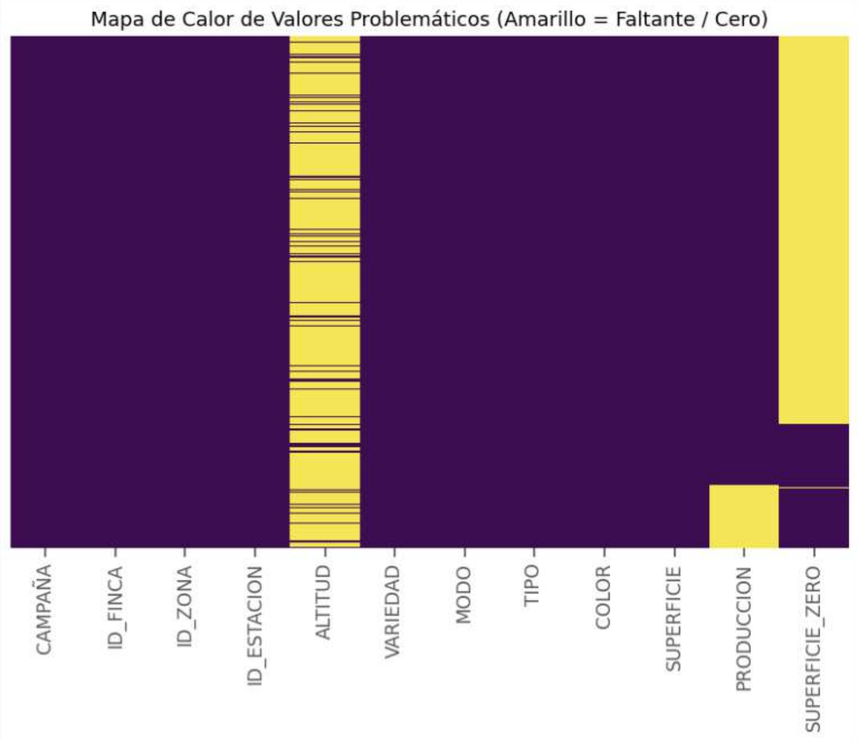

01 Limpieza exhaustiva

Tratamiento de valores faltantes y eliminación de registros inconsistentes para asegurar la máxima calidad de la información base.

02 Transformación de variables

Conversión de atributos categóricos (zona, variedad) a formato numérico mediante One-Hot Encoding, generando un total de 180 variables.

03 Ingeniería de características

Integración de datos climáticos externos y creación de nuevas variables derivadas, incluyendo métricas de producción histórica.

04 División estratégica del dataset

Separación en conjuntos de entrenamiento (5,985 registros) y validación (1,497 registros) para una evaluación robusta de la generalización.

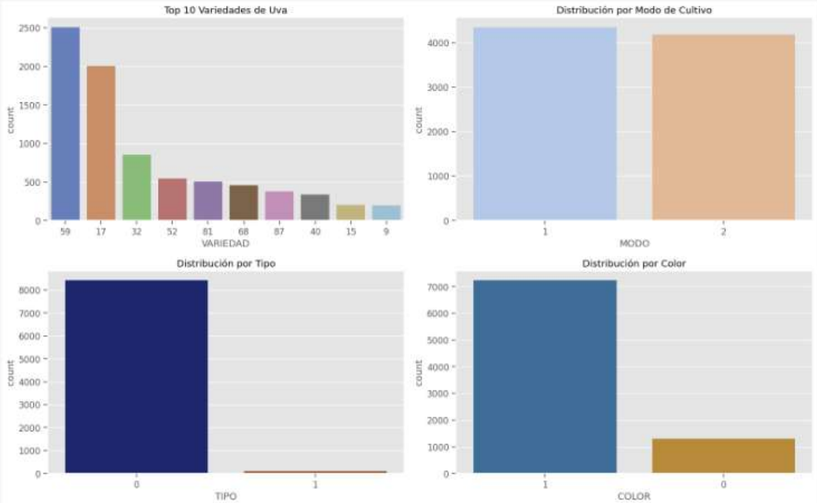

Enfoque de Modelado

Comparativa de rendimiento predictivo (R^2)

¿Qué significa R^2?

El coeficiente de determinación (R^2) indica qué porcentaje de la variabilidad de la producción es explicado por el modelo.

→ **Un valor de 0.75 significa que el modelo captura el 75% de los patrones de producción.**

Hallazgos Clave

- AutoML (AutoGluon) obtuvo el mejor desempeño, superando a los modelos individuales.
- Los algoritmos de Boosting (CatBoost, XGBoost) mostraron resultados consistentemente superiores a los árboles simples.

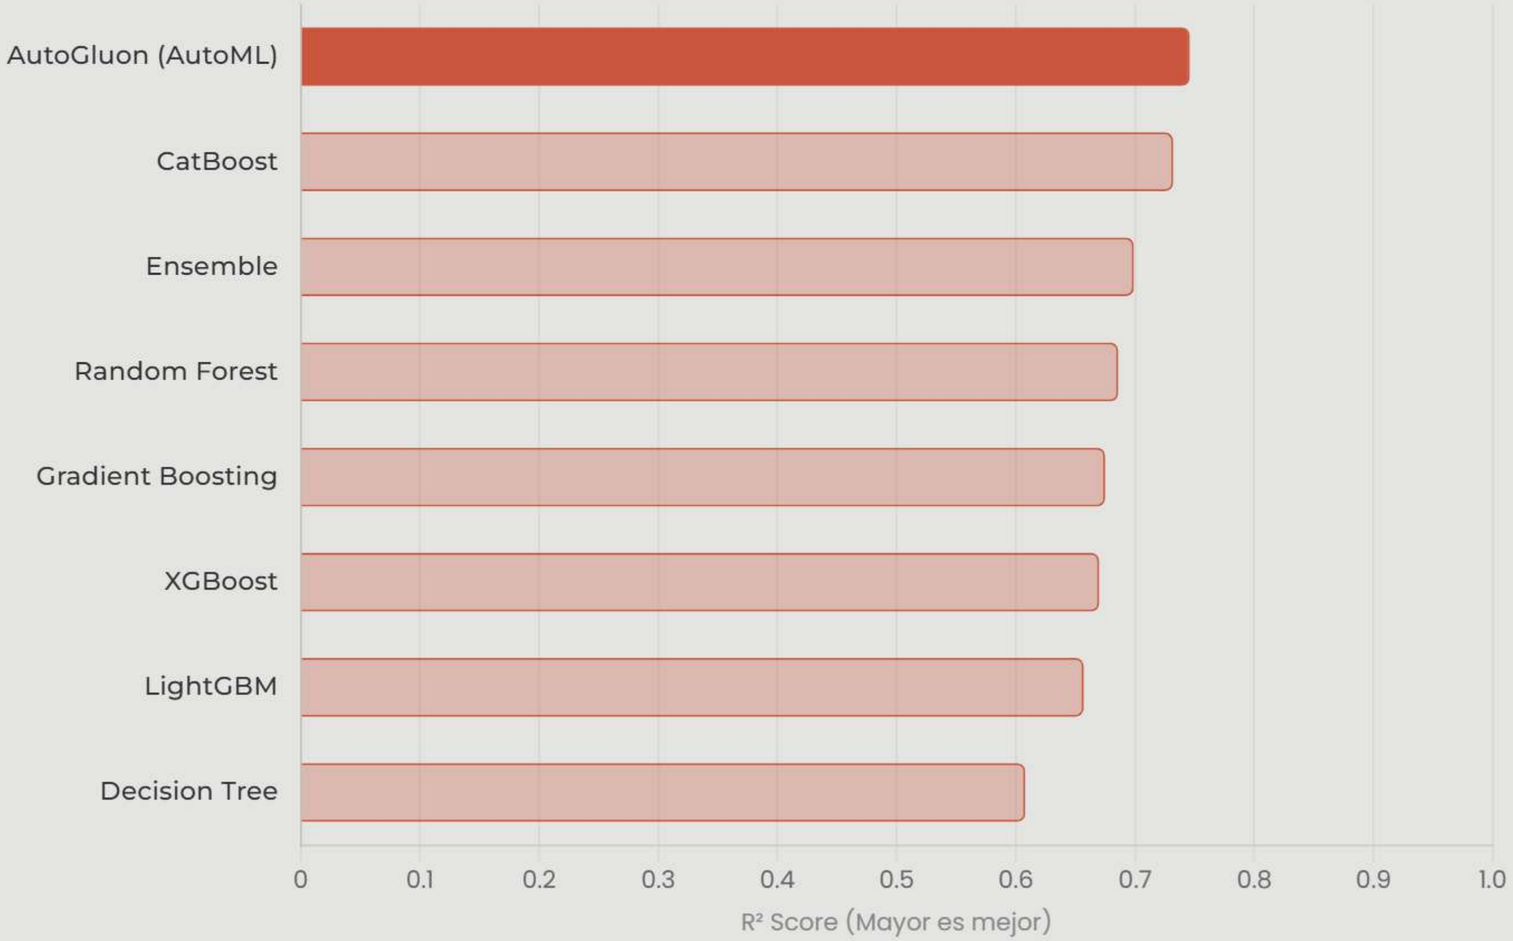

Resultados Obtenidos

Tabla detallada de evaluación y métricas de error

Modelo	RMSE (Menor es mejor)	MAE (Menor es mejor)	R^2 Score (Precisión)
AutoGluon (AutoML) TOP	**6,147**	**3,212**	**0.746**
CatBoost	6,321	3,516	0.732
Ensemble	6,694	3,662	0.699
Random Forest	6,846	3,595	0.686
Gradient Boosting	6,963	3,859	0.675
XGBoost	7,008	3,906	0.670
LightGBM	7,153	3,815	0.657
Decision Tree	7,644	4,268	0.608

Modelo Ganador: AutoGluon

La estrategia de AutoML superó a todos los modelos individuales al combinar automáticamente las fortalezas de múltiples algoritmos.

Error de 6 toneladas por finca aprox.

Capacidad Predictiva

~75%

Variabilidad explicada

Reducción de Error

-19.6%

vs Árbol de Decisión

Variables Más Influyentes

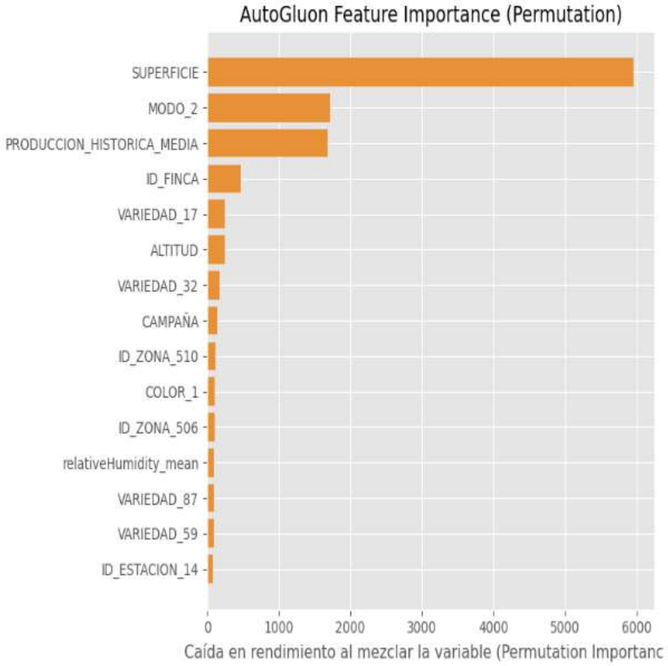

Producción Histórica

El rendimiento de campañas anteriores es el predictor más fuerte del comportamiento futuro (inercia productiva).

Superficie Cultivada

Variable estructural determinante; escala directamente el volumen de producción total esperado.

Variables Climáticas

Precipitación acumulada y temperatura media definen el potencial agrónomo de la campaña actual.

Características de la Parcela

Factores físicos como altitud y pendiente ajustan la capacidad productiva del terreno.

Ubicación y Zona

Captura efectos regionales latentes, tipos de suelo predominantes y microclimas específicos.

Explicabilidad – Evitar la "Caja Negra"

La "Caja de Cristal" de nuestras predicciones

Transparencia total: Este gráfico nos permite ver exactamente cómo "piensa" el algoritmo, ordenando de arriba a abajo los factores que más impactan en la cosecha final.

El peso del clima y el terreno: Variables como la superficie y la altitud son los verdaderos motores de la predicción.

Lectura visual: Cada punto es una finca en una campaña. Los colores cálidos (rojo) indican valores altos de esa variable. Si los puntos rojos se desplazan a la derecha, significa que ese factor está sumando kilos a la producción estimada; si van a la izquierda, está restando.

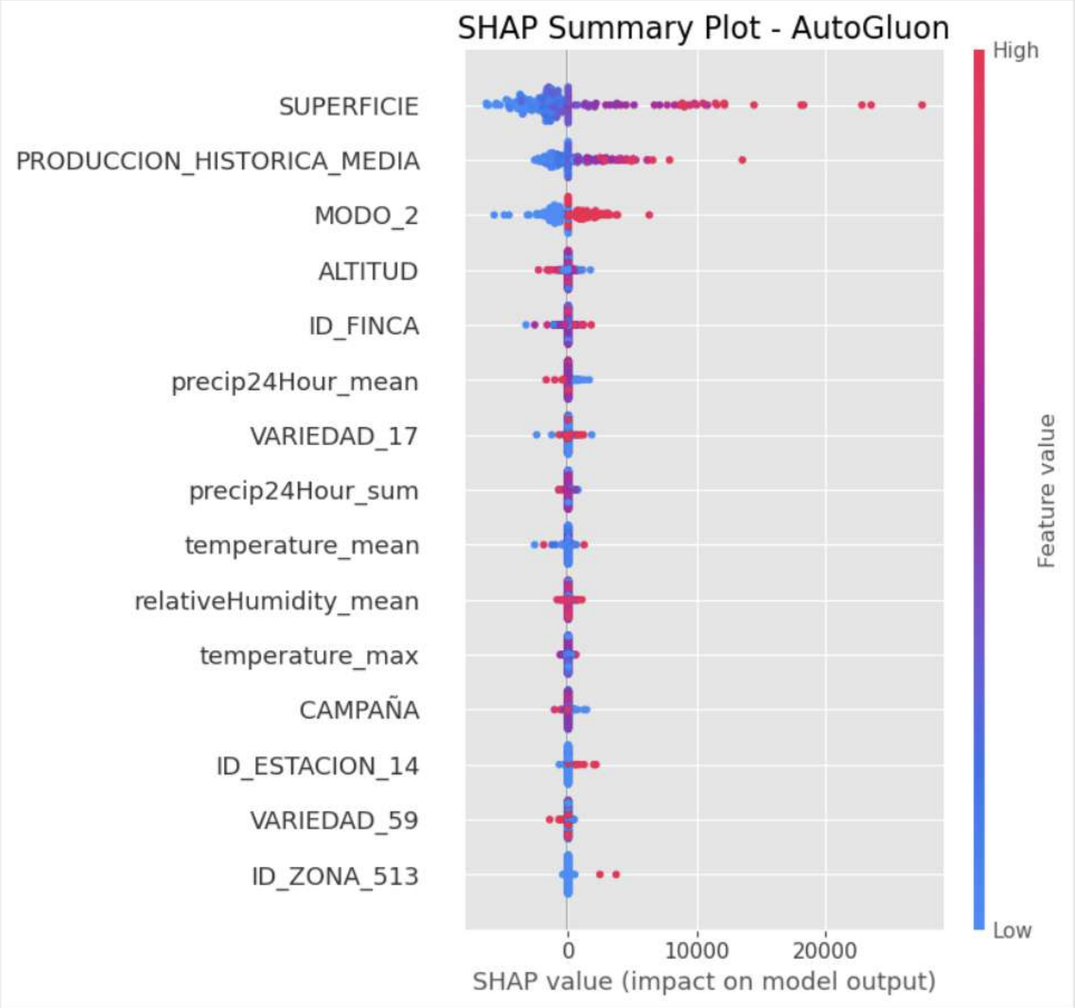

Impacto para el Negocio

Valor Estratégico para "*Se nos fue de las Manos*"

La capacidad de anticipar la producción permite optimizar toda la cadena de valor, desde la logística hasta la comercialización.

01 **Anticipación Operativa y Logística**

Prever el volumen exacto de uva por finca permite dimensionar con meses de antelación la contratación de **personal** para la vendimia, el alquiler de **maquinaria** y el **espacio** necesario en bodega.

02 **Mitigación de la Incertidumbre Financiera**

Sustituimos las estimaciones tradicionales por previsiones basadas en el cruce de históricos y clima, permitiendo un ajuste mucho más riguroso de los **presupuestos y la planificación de ventas**.

03 **Identificación de riesgos climáticos**

Al comprender matemáticamente cómo las variables de temperatura y humedad afectan a cada variedad, el negocio puede activar planes de contingencia antes de que la producción se vea mermada irremediablemente.

Evolución y Próximos Pasos

Enriquecimiento Agronómico

Implementación de variables de **calidad del suelo**, tipo de suelo y edad de las parras de uvas para dotar al algoritmo de un contexto biológico mucho más preciso.

Retraining y Nuevas Fuentes

Integración del modelo predictivo con datos de estaciones meteorológicas y **sensores IoT** en las fincas para reajustar las estimaciones semana a semana de forma automática.

Despliegue de un Dashboard

Creación de una **interfaz visual** donde los responsables de campo y negocio puedan consultar predicciones y simular distintos escenarios sin interactuar con el código.